

ALEXANDRE TEIXEIRA

Ingénieur IA · GenAI & systèmes LLM en production

alexandrete13@gmail.com ♦ +33 7 86 01 55 04 ♦ [LinkedIn](#) ♦ [GitHub](#) ♦ [Portfolio](#) ♦ Paris, France

Ingénieur IA 0 → 1 — je transforme des problèmes métier complexes en produits IA déployés et adoptés. Mon approche : comprendre le terrain, simplifier le problème et construire de l'idée jusqu'à l'impact.

FORMATION

Université de Technologie de Compiègne (UTC)

Diplôme d'Ingénieur en Informatique (grade Master)

2022 – 2026

Compiègne

– IA, optimisation, recherche opérationnelle, logique & résolution par recherche, cybersécurité.

Shanghai University — UTSEUS

Semestre d'échange en Intelligence Artificielle

sept. 2024 – janv. 2025

Shanghai

– Natural Language Processing, IA générative, analyse de données, data visualization.

EXPÉRIENCE PROFESSIONNELLE

Ingénieur IA, SNCF · Stage

Plateforme IA multimodale de synthèse de réunions

sept. 2025 – févr. 2026

Paris

- Conception d'une plateforme interne multimodale utilisée par plusieurs équipes pour RFI, visios et réunions physiques.
- **90 % des audios traités en < 5 min** : transcription, diarisation et synthèse multi-locuteurs.
- Détection des slides clés + VLM pour enrichir automatiquement les résumés avec le contexte visuel.
- Développement 0 → prod (React, Python, Azure AI Services, Docker, Jenkins).
- RFI de **15 fournisseurs IA** (Mistral AI, IBM, LinkUp, Vespa, entre autres) ; accompagnement du déploiement interne de **Mistral Code** pour les équipes d'ingénierie.

Ingénieur IA — Mission Junior-Entreprise, Renault / Alpine

Whiteboard IA pour industrialiser les AMDEC

mars 2025 – juin 2025

Compiègne

- Conception d'un whiteboard collaboratif augmenté par IA pour générer et structurer des AMDEC à grande échelle.
- LLM + RAG pour proposer risques, causes, effets et actions, avec validation par l'expert.
- Inférence industrialisée sur cluster **8× NVIDIA A100** avec vLLM et load balancing.

Ingénieur IA, SNCF · Stage

Assistant GenAI d'automatisation du support DevOps N1

sept. 2023 – févr. 2024

Lyon

- Conception **seul de 0 à 1** d'un assistant RAG ; MVP fonctionnel livré en **3 mois**, de l'architecture au déploiement.
- **82 % des tickets N1 résolus automatiquement** sur ServiceNow, supprimant l'essentiel du traitement manuel.
- Produit industrialisé : **3 000+ utilisateurs mensuels**, équipe de 25 personnes ; présenté sur BFM Business.

PROJETS SÉLECTIONNÉS

Étude comparative CNN / Transformers pour l'imagerie médicale 3D — avec UCL

University College London

févr. 2026 – auj.

- Benchmark CNN / Transformers : performance, complexité et contraintes d'inférence.

Plateforme LLM on-premise pour les étudiants de l'UTC

févr. – juil. 2025

- Plateforme LLM on-premise (OpenWebUI + Ollama, RTX 5090) sur les serveurs UTC, ouverte à tous les étudiants.

AlphaZero from scratch — jeux Gopher & Dodo

2024

- MCTS, self-play et deep reinforcement learning ; réseau résiduel PyTorch avec têtes policy et value.

COMPÉTENCES TECHNIQUES

IA / LLM Engineering: PyTorch, TensorFlow, Hugging Face, vLLM, LangChain, RAG, embeddings, vector databases, VLM

Machine Learning: CNNs, Transformers, ResNet, Scikit-learn, entraînement & évaluation de modèles

Cloud / DevOps: Azure AI Services, Azure OpenAI, Docker, Kubernetes, Jenkins, Harbor, Artifactory, GitLab CI/CD

Développement: Python, React, FastAPI, Flask, Pydantic, PostgreSQL, REST APIs, SQL, Pandas, NumPy

LANGUES & ENGAGEMENTS

Langues: Français (natif) · Anglais (professionnel) · Chinois (notions)

Responsable Partenariats, Imaginarium Festival (2022–2023) — sponsoring d'un festival étudiant au budget de 600 000 €.

Founder Breakfast, Shanghai (2024–2025) — échanges avec des fondateurs de startups sur l'innovation portée par l'IA.