

ALEXANDRE TEIXEIRA

Ingénieur IA · GenAI & systèmes LLM en production

alexandretei13@gmail.com ◇ +33 7 86 01 55 04 ◇ **LinkedIn** ◇ **GitHub** ◇ **Portfolio** ◇ Paris, France

Ingénieur IA 0→1 — je transforme des problématiques métier complexes en produits IA déployés et adoptés. Mon approche : comprendre le terrain, simplifier le problème, et construire de l'idée jusqu'à l'impact.

FORMATION

Université de Technologie de Compiègne (UTC) <i>Diplôme d'Ingénieur en Informatique (grade Master)</i> – IA, optimisation, recherche opérationnelle, logique & résolution par recherche. – Cours complémentaires : psychologie de l'apprentissage, gestion de projet et marketing de l'innovation responsable.	2022 – 2026 Compiègne
Shanghai University — UTSEUS <i>Semestre d'échange en Intelligence Artificielle</i> – Natural Language Processing, IA générative, analyse de données, data visualization.	2024 – 2025 Shanghai

EXPÉRIENCE PROFESSIONNELLE

Ingénieur IA, SNCF · Stage <i>Plateforme IA multimodale de synthèse de réunions</i> – Les RFI, visios et réunions en présentiel génèrent des heures d'audio qu'aucune équipe n'avait le temps de dépouiller. – Construit la plateforme 0→prod : transcription, diarisation, synthèse, détection des slides clés et VLM pour le contexte visuel (React, Python, Azure AI Services, Docker, Jenkins). – 90 % des audios traités en < 5 min ; adoptée par plusieurs équipes. – Référent technique de l'équipe sur les choix IA : RFI menée sur 15 fournisseurs IA (Mistral AI, IBM, LinkUp, Vespa) et déploiement interne de Mistral Code.	sept. 2025 – févr. 2026 Paris
Ingénieur IA — Mission Junior-Entreprise, Renault / Alpine <i>Whiteboard IA pour industrialiser les AMDEC</i> – L'analyse de risques AMDEC était manuelle et dépendante des experts, ce qui limitait le nombre de processus couverts. – Conception d'un whiteboard collaboratif augmenté par IA : le LLM + RAG proposent risques, causes et actions, les experts valident. – Inférence industrialisée sur cluster 8× NVIDIA A100 avec vLLM et load balancing.	mars 2025 – juin 2025 Compiègne
Ingénieur IA, SNCF · Stage <i>Assistant GenAI d'automatisation du support DevOps N1</i> – Le groupe cherchait où le GenAI pouvait avoir un impact ; j'ai identifié le besoin sur le support DevOps N1, où les tickets ServiceNow répétitifs étaient traités manuellement. – Cadrage du cas d'usage et conception de l'assistant RAG seul de 0 à 1 , de l'architecture au déploiement ; MVP en 3 mois. – 82 % des tickets N1 résolus automatiquement ; 3 000+ utilisateurs mensuels , équipe de 25 personnes, présenté sur BFM Business. – Le produit a ensuite grandi à l'échelle du groupe pour devenir SNCF GPT , toujours en service aujourd'hui sur l'architecture que j'ai conçue.	sept. 2023 – févr. 2024 Lyon

PROJETS SÉLECTIONNÉS

Étude comparative CNN / Transformers pour l'imagerie médicale 3D — avec UCL <i>University College London — benchmark performance, complexité et contraintes d'inférence.</i>	févr. 2026 – auj.
Plateforme LLM on-premise (UTC) <i>(OpenWebUI + Ollama, RTX 5090) sur les serveurs de l'UTC, ouverte à tous les étudiants.</i>	févr. – juil. 2025
AlphaZero from scratch — jeux Gopher & Dodo <i>MCTS, self-play et deep RL ; réseau résiduel PyTorch avec têtes policy et value.</i>	2024

COMPÉTENCES TECHNIQUES

IA / LLM Engineering: PyTorch, Hugging Face, vLLM, LangChain, RAG, embeddings, vector databases, VLM
Machine Learning: CNNs, Transformers, ResNet, Scikit-learn, entraînement & évaluation de modèles
Cloud / DevOps: Azure AI Services, Azure OpenAI, Docker, Kubernetes, Jenkins, GitLab CI/CD
Développement: Python, React, FastAPI, PostgreSQL, REST APIs, SQL, Pandas, NumPy

LANGUES & ENGAGEMENTS

Langues — Français (natif) · Anglais (professionnel) · Chinois (notions).	
Responsable Partenariats, Imaginarium Festival — festival étudiant, sponsoring 600 000 EUR.	2022 – 2023
Founder Breakfast, Shanghai — échanges avec des fondateurs de startups sur l'IA.	2024 – 2025