

ALEXANDRE TEIXEIRA

AI Engineer · GenAI & Production LLM Systems

alexandretei13@gmail.com ◇ +33 7 86 01 55 04 ◇ **LinkedIn** ◇ **GitHub** ◇ **Portfolio** ◇ Paris, Fr

Ingénieur IA 0→1 — je transforme des problématiques métier complexes en produits IA déployés et adoptés. Mon approche : comprendre le terrain, simplifier la problématique, et construire de l'idée jusqu'à l'impact.

Formation

Université de Technologie de Compiègne (UTC) ***2022 – 2026***
Diplôme d'Ingénieur en Informatique (grade Master) Compiègne
– IA, optimisation, recherche opérationnelle, logique & résolution par recherche.

Shanghai University — UTSEUS ***2024 – 2025***
Semestre d'échange en Intelligence Artificielle Shanghai
– Natural Language Processing, IA générative, analyse de données, data visualization.

Expérience professionnelle

Ingénieur IA, SNCF · Stage ***sept. 2025 – févr. 2026***
Plateforme IA multimodale de synthèse de réunions Paris

– Les RFI, visios et réunions en présentiel généraient des heures d'audio qu'aucune équipe n'avait le temps de dépouiller.
– Construire **la plateforme 0→prod** : transcription, diarisation, synthèse, détection des slides clés et VLM pour le contexte visuel (React, Python, Azure AI Services, Docker, Jenkins).
– **90 % des audios traités en < 5 min** ; adoptée par plusieurs équipes.
– Référent technique de l'équipe sur les choix **IA : RFI** menée sur 15 fournisseurs IA **(Mistral AI, IBM, LinkUp, Vespa**) et déploiement interne de Mistral Code.

Ingénieur IA — Mission Junior-Entreprise, Renault / Alpine ***mars 2025 – juin 2025***
Whiteboard IA pour industrialiser les AMDEC Compiègne

– L'analyse de risques AMDEC était manuelle et dépendante des experts, ce qui limitait le nombre de processus couverts.
– Conception d'un whiteboard collaboratif augmenté par IA : le LLM + RAG proposent risques, causes et actions, les experts valident.
– Inférence industrialisée sur cluster **8× NVIDIA A100** avec vLLM et load balancing.

Ingénieur IA, SNCF · Stage ***sept. 2023 – févr. 2024***
Assistant GenAI d'automatisation du support DevOps N1 Lyon

– Le groupe cherchait où le GenAI pouvait avoir un impact ; j'ai identifié le besoin sur le support DevOps N1, où les tickets ServiceNow répétitifs étaient traités manuellement.
– Cadrage du cas d'usage et conception de l'assistant RAG **seul de 0 à 1**, de l'architecture au déploiement ; MVP en 3 mois.
– **82 % des tickets N1 résolus automatiquement** ; **3 000+ utilisateurs mensuels**, équipe de 25 personnes, présenté sur BFM Business.
– Le produit a ensuite grandi à l'échelle du groupe pour **devenir SNCF GPT**, toujours en service aujourd'hui sur l'architecture que j'ai conçue.

Projets sélectionnés

Étude comparative CNN / Transformers pour l'imagerie médicale 3D — avec UCL ***févr. 2026 – auj.***
University College London — benchmark performance, complexité et contraintes d'inférence.

Plateforme LLM on-premise (UTC) ***févr. – juil. 2025***
(OpenWebUI + Ollama, RTX 5090) sur les serveurs de l'UTC, ouverte à tous les étudiants.

AlphaZero from scratch — jeux Gopher & Dodo ***2024***
MCTS, self-play et deep RL ; réseau résiduel PyTorch avec têtes policy et value.

Compétences techniques

IA / LLM Engineering: PyTorch, Hugging Face, vLLM, LangChain, RAG, embeddings, vector databases, VLM
Machine Learning: CNNs, Transformers, ResNet, Scikit-learn, entraînement & évaluation de modèles
Cloud / DevOps: Azure AI Services, Azure OpenAI, Docker, Kubernetes, Jenkins, GitLab CI/CD
Développement: Python, React, FastAPI, PostgreSQL, REST APIs, SQL, Pandas, NumPy

Langues & engagements

Langues — Français (natif) · Anglais (professionnel) · Chinois (notions).
Responsable Partenariats, Imaginarium Festival — festival étudiant, sponsoring 600 000 EUR. ***2022 – 2023***
Founder Breakfast, Shanghai — échanges avec des fondateurs de startups sur l'IA. ***2024 – 2025***